

基于 LSTM 与 XGBoost 组合模型的 超短期电力负荷预测

陈振宇^{1,2}, 刘金波³, 李晨⁴, 季晓慧⁴, 李大鹏¹, 黄运豪¹,
狄方春¹, 高兴宇⁵, 徐立中⁶

(1. 电力调度自动化技术研究与系统评价北京市重点实验室(中国电力科学研究院有限公司),
北京市 海淀区 100192;

2. 国家电网有限公司 大数据中心, 北京市 西城区 100031;

3. 国家电网有限公司 国家电力调度控制中心, 北京市 西城区 100031;

4. 中国地质大学(北京) 信息工程学院, 北京市 海淀区 100083;

5. 中国科学院 微电子研究所, 北京市 朝阳区 100029;

6. 国网浙江省电力有限公司, 浙江省 杭州市 310007)

Ultra Short-term Power Load Forecasting Based on Combined LSTM-XGBoost Model

CHEN Zhenyu^{1,2}, LIU Jinbo³, LI Chen⁴, JI Xiaohui⁴, LI Dapeng¹,
HUANG Yunhao¹, DI Fangchun¹, GAO Xingyu⁵, XU Lizhong⁶

(1. Beijing Key Laboratory of Research and System Evaluation of Power Dispatching Automation Technology
(China Electric Power Research Institute), Haidian District, Beijing 100192, China;

2. Big Data Center, SGCC, Xicheng District, Beijing 100031, China;

3. National Power Dispatch and Control Center, SGCC, Xicheng District, Beijing 100031, China;

4. School of Information Engineering, China University of Geosciences, Haidian District, Beijing 100083, China;

5. Institute of Microelectronics, Chinese Academy of Sciences, Chaoyang District, Beijing 100029, China;

6. State Grid Zhejiang Electric Power Company, Hangzhou 310007, Zhejiang Province, China)

ABSTRACT : Accurate power load forecasting provides effective and reliable guidance for power grid construction and operation, and plays a very important role in power system. In order to improve accuracy of power load forecasting, this paper proposes a combined forecast model based on LSTM (Long Short Term Memory Network) and XGBoost (eXtreme Gradient Boosting). The LSTM forecast model and the XGBoost forecast model are firstly established and the power load is predicted using the two models respectively. Then the combined model is used to predict the power load, using error reciprocal method to combine the results from the two single models. Through experimental verification of the power load data of 2016 Electrician Mathematical Contest in Modeling, the MAPE (mean absolute percentage error) error of the combined model is 0.57%, significantly lower than any single forecast model. Compared with GRU (gated recurrent unit) and

XGBoost combined forecasting model, the combined forecasting model proposed in this paper has higher accuracy for ultra-short-term power load.

KEY WORDS: power load; ultra short-term; load forecasting; LSTM network; XGBoost; combined model

摘要 : 为进一步提高电力负荷预测精度, 提出了基于 LSTM (long short term memory network, LSTM) 和 XGBoost (eXtreme gradient boosting) 的组合预测模型。针对电力负荷数据, 首先建立了 LSTM 预测模型和 XGBoost 预测模型, 然后使用误差倒数法将 LSTM 与 XGBoost 组合起来进行预测。采用 2016 年电工数学建模竞赛的电力负荷数据进行算例分析, 结果表明所构建的 LSTM 和 XGBoost 组合预测模型的 MAPE (mean absolute percentage error) 为 0.57%, 明显低于单一预测模型。将上述方法与 GRU (gated recurrent unit) 和 XGBoost 两者组合的预测模型相比较, 结果表明所提出的方法具有更高的超短期电力负荷预测精度。

关键词 电力负荷; 超短期; 负荷预测; LSTM 网络; XGBoost; 组合模型

DOI : 10.13335/j.1000-3673.pst.2019.1566

基金项目: 国家电网有限公司总部科技项目“大电网理想调度及知识发现关键技术研究与应用”(52110418002A)。

Project Supported by Science and Technology Foundation of SGCC (52110418002A).

0 引言

电力负荷预测是基于一个地区的历史电力负荷数据预测未来一段时间内该地区的电力消耗^[1,2]。随着电网智能化的发展,对电力负荷预测精度的要求也逐步提升^[1-7]。相关研究表明,用电负荷预测的误差每增加 1%,电力系统每年的运行成本将增加数千万元^[8]。因此迫切需要不断提高电力负荷预测精度。

常用的精度较高的超短期电力负荷预测方法有时间序列分析和机器学习两种^[1-3]。时间序列分析包括自回归方法^[9]、指数平滑方法^[10]和累积自回归滑动平均方法^[11]等。时间序列分析的缺点是当研究对象在所选时间序列内有特殊变化时间段、无适应性规律时该预测方法无法使用。机器学习包括支持向量机^[12-14]、随机森林^[15]、广义回归神经网络和集成算法^[16-19]等。近年来,机器学习中以循环神经网络和卷积神经网络为代表的深度学习方法以其强大的网络模型结构在电力负荷预测中取得了较好的效果^[20-25]。

组合预测模型将上述几种方法组合起来进行电力负荷预测,以进一步提高预测精度^[26-27]。已有研究将粒子群优化的人工神经网络和广义回归神经网络进行组合^[28];将回归分析模型、弹性系数模型、灰色预测模型和时间序列模型进行组合^[30]。上述组合模型精度均高于单一预测模型的精度。

XGBoost (eXtreme gradient boosting)算法已在众多预测领域取得了较好效果^[29-32]。LSTM (long short term memory network)是一种 RNN (recurrent neural network)的改进模型,解决了 RNN 的梯度消失和爆炸问题,使网络能够有效地处理长期时间序列数据,已应用于电力负荷预测^[33-35],所得误差明显低于其他方法,极大地提升了电力负荷预测精度。鉴于 LSTM 及 XGBoost 在电力负荷预测上已表现出的良好性能,本文将 LSTM 与 XGBoost 模型进行组合,针对超短期电力负荷进行预测。由于超短期电力负荷预测时间间隔较短,气象变化不明显^[1],因此本文不考虑气象因素。实验结果表明,本文提出的组合模型预测精度高于单一模型预测精度,对于 2016 年电工数学建模竞赛电力负荷数据的预测平均绝对百分比误差 (mean absolute percentage error, MAPE)为 0.57%。

1 基于 LSTM 的电力负荷预测

LSTM 在 RNN 的基础上增加了 3 个门的逻辑控制单元:输入门、遗忘门和输出门^[33]。通过门单

元的逻辑控制决定数据是否更新或是选择丢弃,克服了 RNN 权重影响过大、容易产生梯度消失和爆炸的缺点,使网络可以更好、更快地收敛,能够有效提高电力负荷预测精度。

遗忘门:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (1)$$

输入门:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (2)$$

单元:

$$\begin{aligned} \tilde{c}_t &= \tanh(W_c[h_{t-1}, x_t] + b_c) \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \end{aligned} \quad (3)$$

输出门:

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (4)$$

最终输出:

$$h_t = o_t \odot \tanh(c_t) \quad (5)$$

式(1)中: W_f 是遗忘门的权重矩阵; $[h_{t-1}, x_t]$ 表示将两个向量连接成一个更长的向量; b_f 是遗忘门的偏置项; σ 是 sigmoid 函数。式(2)中: W_i 是输入门的权重矩阵; b_i 是输入门的偏置项。式(3)计算当前时刻的单元状态 c_t 。它是由上一次的单元状态 c_{t-1} 按元素乘以遗忘门 f_t ,再用当前输入的单元状态 \tilde{c}_t 按元素乘以输入门 i_t ,再将两个积加和产生。把 LSTM 关于当前的记忆 \tilde{c}_t 和长期的记忆 c_{t-1} 组合在一起,形成了新的单元状态 c_t 。由于遗忘门的控制,它可以保存时间较为久远的信息,通过输入门的控制,可以保证丢弃一些当前无关紧要的内容。式(4)计算输出门输出。式(5)最终得到 LSTM 输出。

GRU (gated recurrent unit)是 LSTM 的一种变体,GRU 预测方法具有预测精确度高,模型实现简单等特点,在电力负荷预测领域得到广泛使用^[36-38]。GRU 的单元结构包括重置门和更新门两部分,单元结构如图 1 所示。其中重置门 r 决定是否忽略先前的隐藏状态 h ,更新门 z 选择是否用新的隐藏状态 \tilde{h} 更新隐藏状态。




图1 GRU 单元结构

Fig. 1 GRU unit structure

1.1 基于 LSTM 预测的数据处理

电力负荷数据采集可能出现异常,这将导致部分电力负荷数据缺失^[1]。本文假定短时间内数据

不会立刻改变,因此以该缺失数据值相同时刻前两天和后两天的对应数据均值作为该缺失值。

模型采用单点预测,为了得到用来预测的输入序列 X 和输出 y ,对电力负荷的时间序列数据集进行构造。对当前预测时刻 t ,将 $t-n$ 至 $t-1$ 时刻的电力负荷数据作为模型的输入序列 X ,当前时刻的电力负荷数据作为输出 y 。

1.2 基于 LSTM 预测的模型构造

LSTM 和 GRU 作为 RNN 的改进型,原理相似,所构建的网络结构也相似。本文所构造的 LSTM 和 GRU 网络模型,除网络单元外其他均相同。以 LSTM 为例,构造 LSTM 电力负荷预测模型。构造的 LSTM 网络结构如图 2 所示。

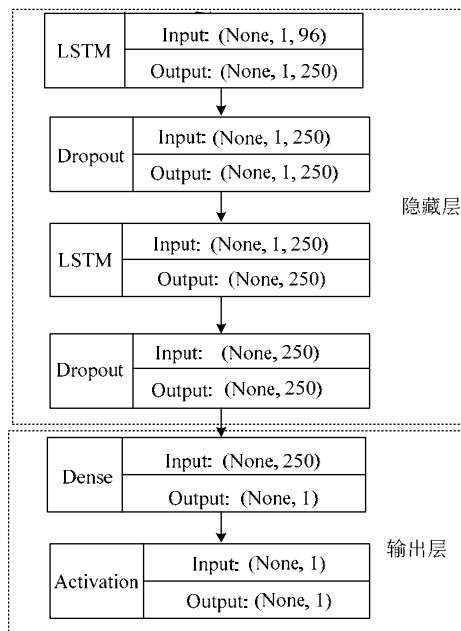


图 2 电力负荷预测的 LSTM 网络结构

Fig. 2 LSTM network structure for power load forecasting

为满足网络输入要求,原始负荷时间序列在输入层被初步处理。具体对电力负荷数据采用如式(6)所示的离差标准化进行归一化,将数据线性映射至 0-1 范围内。

$$x_i^* = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (6)$$

式中: x_{\min} 是电力负荷数据中的最小值; x_{\max} 是电力负荷数据中的最大值; x_i 是需要标准化的电力负荷数据。

隐藏层采用 LSTM 细胞和 Dropout 搭建双层循环神经网络。由于 LSTM 神经网络模块的层数越多,其学习能力越强,但是层数过多又会造成网络训练难以收敛,因此训练过程中网络的层数一般不超过 3^[31,39],本文采用 2 层。本文隐藏层的每个 LSTM

层后面加入了一个 Dropout 层,在前向传播时让神经元的激活值以指定的概率停止工作,从而增强模型的泛化性,防止过拟合。

输出层使用全连接层对结果进行降维,并在得到预测数据后进行反归一化,最终得出预测结果。网络训练采用 Adam 优化算法^[40]。

2 基于 XGBoost 的电力预测

XGBoost 是对 Boosting 算法的一种优化,它集成弱分类器为一个强分类器^[41]。XGBoost 算法通过不断迭代,生成一棵新树拟合前一棵树的残差,随着迭代次数的增多,精度不断提高。因此 XGBoost 算法能够对电力负荷数据进行较好的拟合,从而降低预测误差,取得较高的预测精度。

2.1 XGBoost 建立回归树拟合

所用树模型是 CART 回归树模型^[41]。XGBoost 模型如下所示:

$$\hat{y}_i = \sum_{t=1}^n f_t(x_i), f_t \in F \quad (7)$$

式中: n 为树的数目; f_t 为函数空间 F 中的一个函数; \hat{y}_i 为预测值; x_i 为输入的第 i 个数据; F 为所有可能的 CART 集合。

每一次迭代不影响模型,即原来的模型保持不变,将一个新的函数添加到模型里。一个函数对应一棵树,新生成的树拟合上次预测的残差,迭代过程如下所示:

$$\begin{cases} \hat{y}_i^{(0)} = 0 \\ \hat{y}_i^{(1)} = f_1(x_i) = \hat{y}_i^{(0)} + f_1(x_i) \\ \hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i) \end{cases} \quad (8)$$

XGBoost 的目标函数如下所示:

$$X_{\text{obj}} = \sum_{i=1}^n l(y, \hat{y}) + \sum_{k=1}^K \Omega(f_k) \quad (9)$$

$$\Omega(f_k) = \gamma T + \lambda \frac{1}{2} \sum_{j=1}^T \omega_j^2 \quad (10)$$

式(9)中: $\sum_{i=1}^n l(y, \hat{y})$ 用来衡量预测分数和真实分数的

差距; $\sum_{k=1}^K \Omega(f_k)$ 是正则化项。式(10)中: T 为叶子

结点的个数; ω 为叶子节点的分数; γ 的用途为控制叶子结点的个数; λ 保证叶子节点的分数不至于太大。正则化的目标是选择简单的预测函数,防止模型过拟合。当正则化参数为零时, XGBoost 退化为传统的 Boosting 模型。模型的迭代采用 additive training 的方式以进一步最小化目标函数^[41-42]。每次迭代将目标函数更新为

$$\tau^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(X_i)) + \Omega(f_t) \quad (11)$$

为了找到能够最小化目标函数的 f_t , XGBoost 利用其在 $f_t = 0$ 处的泰勒二阶展开近似它, 将损失函数的泰勒级数推广到 2 阶。所以目标函数近似为

$$\tau^{(t)} \approx \sum_{i=1}^n [l(y_i, \hat{y}_i^{(t-1)} + f_t(X_i)) + \frac{1}{2} h_t f_t^2(X_i)] + \Omega(f_t) \quad (12)$$

公式(12)将每个数据的损失函数值加起来, 过程如下所示:

$$\begin{aligned} X_{\text{obj}} &= \sum_{i=1}^n [g_i f_t(x_i) + \frac{1}{2} h_t f_t^2(x_i)] + \Omega(f_t) = \\ &= \sum_{i=1}^n [g_i w_q(x_i) + \frac{1}{2} h_t w_q^2(x_i)] + \Omega(f_t) + \lambda T + \lambda \frac{1}{2} \sum_{j=1}^T \omega_j^2 = \\ &= \sum_{j=1}^T [(\sum_{i \in I_j} g_i) w_j + \frac{1}{2} (\sum_{i \in I_j} h_i + \lambda) w_j^2] + \lambda T \quad (13) \end{aligned}$$

式中: X_{obj} 为目标函数; $g_i = \partial \hat{y}^{t-1} l(y_i, \hat{y}^{t-1})$ 为一阶导数; $h_i = \partial^2 \hat{y}^{t-1} l(y_i, \hat{y}^{t-1})$ 为二阶导数。

公式(13)将目标函数改写成关于叶子结点分数 ω 的一元二次函数, 求解所得的最优 ω 和目标函数值分别如下所示:

$$\omega_j^* = -\frac{G_j}{H_j + \lambda} \quad (14)$$

$$X_{\text{obj}} = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \lambda T \quad (15)$$

式中: $G_j = \sum_{i \in I_j} g_i$; $H_j = \sum_{i \in I_j} h_i$ 。

训练过程中, 模型不断计算结点损失以选择增益损失最大的叶子结点。模型损失计算过程见图 3。

算法: 增益损失最大结点计算
输入: I 当前节点
输出: d 特征维度
$X_{\text{gain}} \leftarrow 0$ $G \leftarrow \sum_{i \in I} g_i, H \leftarrow \sum_{i \in I} h_i$ For $k=1$ to m do $G_L \leftarrow 0, H_L \leftarrow 0$ For j in sorted(I , by x_{jk}) do $G_L \leftarrow G_L + g_j, H_L \leftarrow H_L + h_j$ $G_R \leftarrow G - G_L, H_R \leftarrow H - H_L$ $X_{\text{score}} \leftarrow \max(X_{\text{score}}, \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{G^2}{H + \lambda})$ end end 输出: 增益损失最大节点

图3 增益损失最大结点计算方法
Fig. 3 Node splitting algorithm

2.2 基于 XGBoost 的模型构造

XGBoost 模型预测时需要确定 3 种参数: 通用参数、辅助参数和任务参数。上升过程中上升模型类型由通用参数确定, 常采用树或线性模型; 辅助参数由所选的上升模型确定; 任务参数指定学习任务和学习目标。

上述 3 种参数对算法性能影响较大的是辅助参数, 包括学习率、树的最大高度和随机采样比例^[43]。因为树的最大高度影响最终结果, 因此首先对该参数进行调优。调优方法首先给其他参数一个初始值, 其中重要参数设置为常见的典型值, 如表 1 所示。其他参数设置为默认值。改变树的最大高度比较测试数据的损失, 如图 4 所示, 可得树的最大高度为 5 时, 测试数据的误差最小。

表 1 参数初始化值 Tab. 1 Initial values of parameters	
参数名	初始化值
n_estimators 迭代次数	1000
Gamma 函数	0
Subsample 下采样	0.8
colsample_bytree 列占比	0.8
learning_rate 学习率	0.1




图4 树的最大高度和测试误差

Fig. 4 Maximal depth and the test error of the tree

在确定树的最大高度后, 给出其他参数组合范围, 以搜索遍历方法得出其他参数的最佳组合^[43]。其中学习率范围设置为 0.01~0.9; 迭代次数范围设置为 100~10000; 随机采样比例范围设置为 0~0.9。通过搜索遍历, 最终确定本文所使用的 XGBoost 模型树的最佳参数设置。其中选择提升器选用 gbtrees, 学习率设置为 0.05; 树的最大高度设置为 5; 叶子最小权重和设置为 1; 样本采样比率设置为 0.2; 迭代次数设置为 1000; 评估指标选用 MAPE; 任务函数选择为 Gamma。

3 组合预测方法

如第 1、2 章所述得到 LSTM 及 XGBoost 的预测结果后, 采用如公式(16)所示的误差倒数法对两个预测时序数据进行加权组合, 其中 ω_i 为权值系

数, f_{it} 为 LSTM 或者 XGBoost 所得的预测值。权值系数 ω_i 的计算如公式(17)及(18)所示, 其中 ε_1 、 ε_2 分别为 LSTM 和 XGBoost 的误差。

$$f_t = \omega_1 f_{1t} + \omega_2 f_{2t}, t=1,2,\dots,n \quad (16)$$

$$\omega_1 = \frac{\varepsilon_2}{\varepsilon_1 + \varepsilon_2} \quad (17)$$

$$\omega_2 = \frac{\varepsilon_1}{\varepsilon_1 + \varepsilon_2} \quad (18)$$

由式(16)(17)和(18)可知该方法对误差小的模型会赋予较大的权值系数, 从而使整个组合模型误差趋于减小, 得到误差更小的预测值, 达到提升整体预测精度的效果^[44]。

4 算例分析

4.1 实验数据和实验平台

实验以 2016 年电工数学建模竞赛^[45]提供的 2009 年 1 月 1 日至 2015 年 1 月 10 日的电力负荷为数据, 数据的采样周期为 15min, 每天产生 96 组数据。以 2009 年 1 月 1 日至 2015 年 1 月 6 日的数据为训练数据, 以 2015 年 1 月 7 日至 2015 年 1 月 9 日的负荷数据为测试数据。预测 2015 年 1 月 9 日至 2015 年 1 月 10 日的超短期电力负荷, 并与真实负荷进行对比。预测采用单点预测。

实验平台为装有 NVIDIA Tesla P100 GPU 的服务器。使用 Python 语言实现所提方法, LSTM 模型和 GRU 模型采用的是 Keras 框架, XGBoost 采用 py-xgboost 框架。

4.2 实验评价指标

本文选取 MAPE 作为各个模型预测性能的主要评价指标, 并选择平均误差(mean error, ME)和均方根误差(root mean square error, RMSE)作为辅助评价指标。MAPE、ME 及 RMSE 的计算分别如下所示:

$$X_{MAPE} = \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{y_t} \quad (19)$$

$$X_{ME} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad (20)$$

$$X_{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (21)$$

式中: y_t 为实际电力负荷数据; \hat{y}_t 为预测电力负荷数据; n 为电力负荷数据数量。

4.3 结果分析

实验还与 GRU 与 XGBoost 相组合的预测模型进行了对比。各独立模型预测值与实际值的对比如图 5 所示, 各组合模型预测值与实际值对比如图 6

所示。各模型的逐点相对误差如图 7 所示, MAPE、ME 及 RMSE 值如表 2 所示。

由图 5 可知, LSTM 模型预测精度较 XGBoost 模型低, GRU 模型预测精度最低。由图 6 可知, LSTM 和 XGBoost 的组合预测模型精度高于 GRU

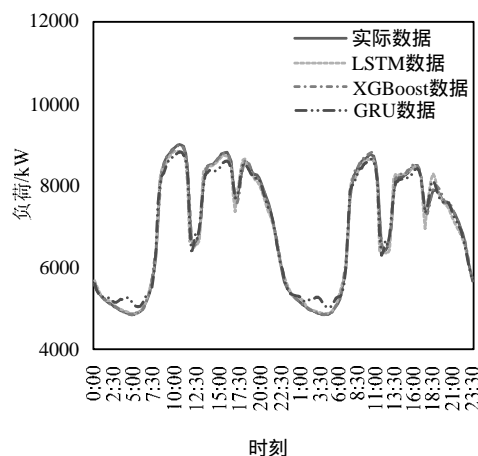


图 5 LSTM、XGBoost 及 GRU 的预测结果对比
Fig. 5 Comparison of the actual data and the forecasted data of LSTM, XGBoost and GRU

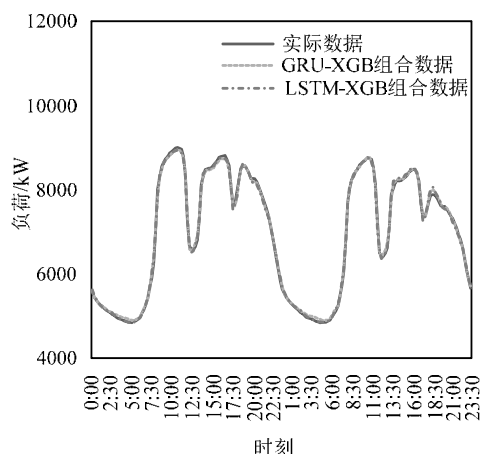


图 6 LSTM-XGBoost 与 GRU-XGBoost 的预测结果对比
Fig. 6 Comparison of the actual data and the forecasted data of LSTM-XGBoost and GRU-XGBoost

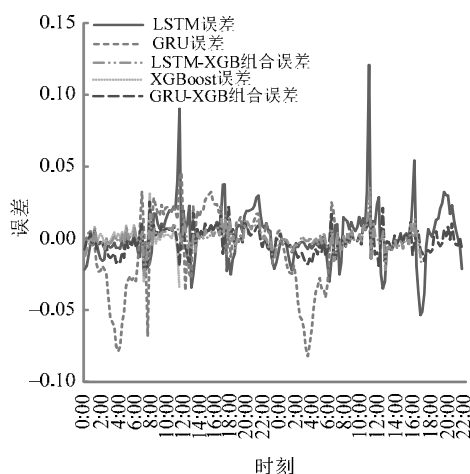


图 7 逐点相对误差对比
Fig. 7 Comparison of the point by point errors

表2 MAPE、RMSE及ME对比
Tab. 2 Comparison of MAPE, RMSE and ME

模型	MAPE	RMSE/kW	ME/kW
GRU	0.0206	164.12	133.01
LSTM	0.0137	146.3	99.62
XGBoost	0.006	61.861	42.794
GRU-XGB	0.0716	59.936	48.16
LSTM-XGB	0.0057	56.581	40.751

和 XGBoost 组合预测模型精度,具有最高的预测精度,其预测曲线与实际曲线变化趋势基本一致。图7也表明本文提出的 LSTM 和 XGBoost 组合预测模型降低了整体预测误差,具有较好的预测效果。由表2可知,本文提出的 LSTM 和 XGBoost 组合模型具有最小的 MAPE、RMSE 及 ME 值,分别为 0.57%、56.581 及 40.751,即具有最高预测精度。

5 结论

LSTM和XGBoost等机器学习模型已经广泛应用于生产生活的各个领域,本文提出的基于 LSTM 与 XGBoost 组合模型,用来进行超短期电力负荷预测。选择 2016 年电工数学建模竞赛数据为例,将 LSTM-XGBoost 模型与 GRU-XGBoost 模型及单一模型实验效果对比,得出如下结论:

1) 本文提出的 LSTM-XGBoost 模型将 LSTM 与 XGBoost 模型采用误差倒数法进行加权组合,修正单一模型误差较大的时序数据,以降低单一预测模型误差。实验结果表明 LSTM 与 XGBoost 的组合模型能有效提高超短期电力负荷预测精度。

2) 通过 GRU-XGBoost 模型与单一模型实验效果对比,表明并非所有模型单一组合都能有效提高预测精度,正确选择参与组合的单一模型是降低预测误差的前提。

3) 在后续研究中,应该重点关注细分领域的负荷预测问题,将数据分析推广到工业、农业和商业等各个具体领域中,有利于结合具体场景挖掘更多有效信息,从而提升预测精度。

4) 未来的电力负荷预测应当结合大数据平台,采用并行集群对大规模数据进行处理,提升数据分析速度,进一步提高预测的实时性。

参考文献

- [1] 康重庆,夏清,刘梅. 电力系统负荷预测[M]. 北京: 中国电力出版社 2007.
- [2] 刘敏,邓勇,何光宇,等. 电力系统超短期负荷预测研究综述[C]//福建省电机工程学会第十五届学术年会. 福州: 福建省电机工程学会, 2015: 1-12.
- [3] Tao H, Shu F. Probabilistic electric load forecasting: a tutorial review [J]. International Journal of Forecasting, 2016, 32(3): 914-938.
- [4] Shi D. Application of outlier mining in power load forecasting[C]//

- International Conference on Computer Application & System Modeling (ICCSM 2010), Taiyuan, 2010: V5-174-V5-176.
- [5] Li H. Short term load forecasting by adaptive neural network[J]. IOP Conference Series: Materials Science and Engineering, DOI: 10.1088/1757-899X/449/1/012028.
- [6] Wang N, Fu P, Chen D, et al. Application of big data method in optimal load dispatching of power plant[J]. Proceedings of the CSEE, 2015, 35(1): 263.
- [7] 张振高,杨正瓴. 短期负荷预测中的负荷求导法及天气因素的使用[J]. 电力系统及其自动化学报, 2006, 18(5): 79-83.
Zhang Zhengao, Yang Zhengyi. Load derivation in short term forecasting using weather factor[J]. Proceedings of the CSU-EPSC, 2006, 18(5): 79-83(in Chinese).
- [8] 张宇航,邱才明,贺兴等. 一种基于 LSTM 神经网络的短期用电负荷预测方法[J]. 电力信息与通信技术, 2017, 15(9): 19-25.
Zhang Yuhang, Qiu Caiming, He Xing, et al. A short-term load forecasting based on LSTM neural network[J]. Electric Power Information and Communication Technology, 2017, 15(9): 19-25(in Chinese).
- [9] Baharudin Z, Kamel N. Autoregressive method in short term load forecast[C]//2008 IEEE 2nd International Power and Energy Conference. Johor Bahru: IEEE, 2008: 1603-1608.
- [10] Ji P, Xiong D, Wang P, et al. A study on exponential smoothing model for load forecasting[C]//2012 Asia-Pacific Power and Energy Engineering Conference. Shanghai: Energy Procedia, 2012: 2884-2887.
- [11] Zhu X, Shen M. Based on the ARIMA model with grey theory for short term load forecasting model[C]//2012 International Conference on Systems and Informatics (ICSAI2012). Yantai: IEEE, 2012: 564-567.
- [12] Ma W M W. Power system short-term load forecasting based on improved support vector machines[C]//2008 International Symposium on Knowledge Acquisition and Modeling. Wuhan: IEEE, 2008: 658-662.
- [13] Huo J, Shi T, Jing C. Comparison of random forest and SVM for electrical short-term load forecast with different data sources[C]//2016 7th IEEE International Conference on Software Engineering and Service Science (ICSESS). Beijing: IEEE, 2016: 1077-1080.
- [14] 蒋敏,顾东健,孔军等. 基于在线序列极限支持向量回归的短期负荷预测模型[J]. 电网技术, 2018, 42(7): 2240-2247.
Jiang Min, Gu Dongjian, Kong Jun, et al. Short-term load forecasting model based on online sequential extreme support vector regression [J]. Power System Technology, 2018, 42(7): 2240-2247(in Chinese).
- [15] Lahouar A, Ben H S J. Day-ahead load forecast using random forest and expert input selection[J]. Energy Conversion and Management, 2015, 103: 1040-1051.
- [16] Papadopoulos S, Karakatsani I. Short-term electricity load forecasting using time series and ensemble learning methods[C]//2015 IEEE Power and Energy Conference at Illinois (PECI), Champaign, IL: IEEE, 2015: 1-6.
- [17] Qiu X, Suganthan P N, Amaratunga G A J. Ensemble incremental learning random vector functional link network for short-term electric load forecasting[J]. Knowledge-Based Systems, 2018, 145(4): 182-196.
- [18] Hayashi Y, Iwamoto S. Long-term load forecasting using improved recurrent neural network[J]. Electrical Engineering in Japan, 2010, 114(8): 41-54.
- [19] 肖白,刘庆永,牛强等. 基于元胞负荷特性分析的 RBF 神经网络空间负荷预测方法[J]. 电网技术, 2018, 42(1): 301-307.
Xiao Bai, Liu Qingyong, Niu Qiang, et al. A spatial load forecasting method based on RBF neural network and cellular load characteristics analysis[J]. Power System Technology, 2018, 42(1): 301-307(in Chinese).
- [20] Li L, Ota K, Dong M. Everything is image: CNN-based short-term

- electrical load forecasting for smart grid[C]//2017 14th International Symposium on Pervasive Systems, Algorithms and Networks & 2017 11th International Conference on Frontier of Computer Science and Technology & 2017 Third International Symposium of Creative Computing (ISPAN-FCST-ISCC). Exeter, 2017: 344-351.
- [21] 毛李帆, 姚建刚, 金永顺, 等. 中长期电力组合预测模型的理论研究[J]. 中国电机工程学报, 2010, 30(16): 53-59.
- Mao Lifan, Yao Jiangang, Jin Yongshun, et al. Theoretical study of combination model for medium and long term load forecasting [J]. Proceedings of the CSEE, 2010, 30(16): 53-59(in Chinese).
- [22] 刘龙龙. 基于 SARIMA 与 SVR 的短期电力负荷预测[D]. 南昌: 东华理工大学, 2018.
- [23] 梁智, 孙国强, 李虎成, 等. 基于 VMD 与 PSO 优化深度信念网络的短期负荷预测[J]. 电网技术, 2018, 42(2): 598-606.
- Liang Zhi, Sun Guoqiang, Li Hucheng, et al. Short-term load forecasting based on VMD and PSO optimized deep belief network [J]. Power System Technology, 2018, 42(2): 598-606(in Chinese).
- [24] 彭文, 王金鑫, 尹山青. 电力市场中基于 Attention-LSTM 的短期负荷预测模型[J]. 电网技术, 2019, 43(5): 1745-1751.
- Peng Wen, Wang Jinrui, Yin Shanqing. Short-term load forecasting model based on attention-LSTM in electricity market[J]. Power System Technology, 2019, 43(5): 1745-1751(in Chinese).
- [25] 张宇帆, 艾芊, 林琳, 等. 基于深度长短时记忆网络的区域级超短期负荷预测方法[J]. 电网技术, 2019, 43(6): 1884-1892.
- Zhang Yufan, Ai Wei, Lin Lin, et al. A very short-term load forecasting method based on deep LSTM RNN at zone level[J]. Power System Technology, 2019, 43(6): 1884-1892(in Chinese).
- [26] 段晶晶. 基于神经网络的短期电力负荷组合预测方法研究[D]. 兰州: 兰州大学, 2017.
- [27] 陈鸿琳, 李欣然, 冷华, 等. 运用 PSO 和 GRNN 的短期负荷二维组合预测[J]. 电力系统及其自动化学报, 2018, 30(2): 85-89.
- Chen Honglin, Li Xinran, Leng Hua, et al. Bidirectional combined short-term load forecasting by using PSO and GRNN[J]. Proceedings of the CSU-EPSA, 2018, 30(2): 85-89(in Chinese).
- [28] 程津, 黎燕, 夏向阳, 等. 基于双组合预测的经济-电力负荷预测模型[J]. 电力科学与技术学报, 2018, 33(3): 20-24.
- Cheng Jin, Li Yan, Xia Xiangyang, et al. Economic-electricity conduction prediction model based on dual combination prediction [J]. Journal of Electric Power Science and Technology, 2018, 33(3): 20-24(in Chinese).
- [29] 蒋晋文, 刘伟光. XGBoost 算法在制造业质量预测中的应用[J]. 智能计算机与应用, 2017(6): 61-63.
- Jiang Jinwen, Liu Weiguang. Application of XGBoost algorithm in manufacturing quality prediction[J]. Intelligent Computer and Applications, 2017(6): 61-63(in Chinese).
- [30] Li L, Situ R, Gao J, et al. A hybrid model combining convolutional neural network with XGBoost for predicting social media popularity [C]//In Proceedings of the 25th ACM international conference on Multimedia(MM'17). New York, USA: ACM, 2017: 1912-1917.
- [31] Pan B. Application of XGBoost algorithm in hourly PM2.5 concentration prediction[J]. IOP Conference Series: Earth and Environmental Science, 2018, 113: 1-7.
- [32] Wang J, Lou C, Yu R, et al. Research on hot micro-blog forecast based on XGBOOST and random forest[M]. Knowledge Science, Engineering and Management, KSEM 2018, Lecture Notes in Computer Science, Springer.
- [33] Graves A. Long short-term memory[M]. Supervised Sequence Labeling with Recurrent Neural Networks. Textbook, Studies in Computational Intelligence, Springer, 2012.
- [34] Li C, Chen Z. Y, Liu J. B, et al. Power load forecasting based on the combined model of LSTM and XGBoost[C]//PRAI '19: Proceedings of the 2019 the International Conference on Pattern Recognition and Artificial Intelligence. Wenzhou, China: ACM, 2019: 46-51.
- [35] Tang D, Li C, Ji X, et al. Power load forecasting using a refined LSTM[C]//In Proceeding of 2019 International Conference on Machine Learning and Computing (ICMLC 2019). Zhuhai, China: ACM, 2019: 104-108.
- [36] 王增平, 赵兵, 纪维佳, 等. 基于 GRU-NN 模型的短期负荷预测方法[J]. 电力系统自动化, 2019, 43(5): 86-95.
- Wang Zengping, Zhao Bing, Ji Weijia, et al. Short-term load forecasting method based on GRU-NN model[J]. Automation of Electric Power Systems, 2019, 43(5): 86-95(in Chinese).
- [37] 牛哲文, 余泽远, 李波, 等. 基于深度门控循环单元神经网络的短期风功率预测模型[J]. 电力自动化设备, 2018, 38(5): 36-42.
- Niu Zhewen, Yu Zeyuan, Li Bo, et al. Short-term wind power forecasting model based on deep gated recurrent unit neural network [J]. Electric Power Automation Equipment, 2018, 38(5): 36-42(in Chinese).
- [38] 张建寰, 吉莹, 陈立东. 深度学习在电力负荷预测中的应用[J]. 自动化仪表, 2019(8): 8-12.
- Zhang Jianwei, Ji Ying, Chen Lidong. Application of deep learning in power load forecasting[J]. Process Automation Instrumentation 2019(8): 8-12(in Chinese).
- [39] 周永生. 基于 LSTM 神经网络的 PM2.5 预测[D]. 长沙: 湖南大学, 2018.
- [40] Wang S, Sun J, Xu Z. Hyper Adam: a learnable task-adaptive Adam for network training[C]//Thirty-Third AAAI Conference on Artificial Intelligence(AAAI). Honolulu, Hawaii, USA, 2019: 5297-5304.
- [41] Chen T, Guestrin C. Xgboost: A scalable tree boosting System [C]//ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco, USA: ACM, 2016: 785-794.
- [42] Gómez-Ríos A, Luengo J, Herrera F. A study on the noise label influence in boosting algorithms: Adaboost, GBM and XGBoost [C]//International Conference on Hybrid Artificial Intelligence Systems (HAIS), 2017: 268-280.
- [43] Aarshay J. Complete guide to parameter tuning in XGBoost [DB/OL]. [2019-05-16]. <https://www.analyticsvidhya.com/blog/2016/03/complete-guide-parameter-tuning-XGBoost-with-codes-python/>.
- [44] 王效. 基于综合模型的电力系统中长期负荷预测方法研究[J]. 华电技术, 2013(6): 40-41.
- Wang Xiao. Research on medium and long term load forecasting method of power system based on comprehensive model[J]. Water Conservancy & Electric Power Machinery, 2013(6): 40-41(in Chinese).
- [45] 中国电机工程学会电工数学专委会. 2016 年电工数学建模竞赛 [DB/OL]. [2018-12-01]. http://shumo.neepu.edu.cn/upload/2016-05/27/dijiujiuediangongshuxuejianmojingsaishiti_2016Ati-dc56c.rar.



陈振宇

收稿日期: 2019-07-24.

作者简介:

陈振宇(1985), 男, 博士, 高级工程师, 研究方向为大数据分析挖掘、人工智能, E-mail: zhenyu-chen@sgcc.com.cn;

刘金波(1975), 男, 硕士, 教授级高级工程师, 研究方向为电力系统调度自动化, E-mail: jinbo-liu@sgcc.com.cn;

高兴宇(1985), 男, 通信作者, 博士, 副研究员, 研究方向为人工智能及应用, E-mail: gaopingyu@ime.ac.cn.

(责任编辑 王金芝)